



SIMONE DE BEAUVOIR
ÉCOLE FRANÇAISE
FONDATION NOUR EL MAAREF - 1992

1ère
NSI

Chapitre 3 : Traitement de données en table

Leçon 4 : Fusion de table

Thème : Traitement de données en table

Enseignant : Housseem Lahiani

Introduction

La fusion de tables est une opération courante dans le traitement des données, permettant d'agréger les informations de plusieurs sources. Lorsque deux tables partagent la même structure (c'est-à-dire le même nombre et le même type d'attributs), il est possible de les combiner en une seule table.

Fusion simple

Imaginons que nous disposions de deux ensembles de données représentant les notes des élèves de deux classes différentes pour un devoir commun :

```
classe_a = [{'nom': 'Alice', 'note': 18}, {'nom': 'Bob', 'note': 15}]
```

```
classe_b = [{'nom': 'Charlie', 'note': 17}, {'nom': 'Dana', 'note': 19}]
```

Pour fusionner ces deux tables, nous pouvons simplement les additionner grâce à l'opérateur `+` de Python :

```
notes_fusionnees = classe_a + classe_b
```

Point de Vigilance : Structures Incompatibles

Si les tables n'ont pas la même structure, leur fusion peut entraîner des complications, rendant la manipulation ultérieure des données difficile ou même impossible sans une normalisation préalable.

Types de Fusion : Concaténation et Jointure

La fusion de tables peut prendre principalement deux formes : la concaténation et la jointure, chacune répondant à des besoins spécifiques.

Concaténation :

La concaténation est le processus d'assemblage de tables selon l'axe des lignes ou des colonnes. Cette méthode est particulièrement utile lorsque les tables à fusionner ont le même ensemble d'attributs (colonnes) mais diffèrent en termes de lignes (enregistrements).

Verticale : Les tables sont empilées l'une sur l'autre, ajoutant des lignes.

```
import pandas as pd

# Première table de clients

clients_1 = pd.DataFrame({

    'ID_client': [1, 2],

    'Nom': ['Alice', 'Bob'],

    'Email': ['alice@example.com', 'bob@example.com']})

# Deuxième table de clients

clients_2 = pd.DataFrame({

    'ID_client': [3, 4],

    'Nom': ['Charlie', 'Dana'],

    'Email': ['charlie@example.com', 'dana@example.com']})

# Concaténation verticale

clients_concatenes = pd.concat([clients_1, clients_2], ignore_index=True)

print(clients_concatenes)
```

Horizontale : Les tables sont alignées côte à côte, ajoutant des colonnes. Le code ci-dessous présente une concaténation horizontale :

```
# Table des noms de clients

noms_clients = pd.DataFrame({

    'ID_client': [1, 2],

    'Nom': ['Alice', 'Bob']})

# Table des adresses des clients

adresses_clients = pd.DataFrame({

    'Email': ['alice@example.com', 'bob@example.com'],

    'Adresse': ['123 Rue A', '456 Rue B']

})

# Concaténation horizontale

clients_et_adresses = pd.concat([noms_clients, adresses_clients], axis=1)

print(clients_et_adresses)
```

La concaténation est généralement simple à réaliser et sert à agréger des données similaires provenant de différentes sources.

Jointure :

La jointure, quant à elle, est une opération plus sophistiquée qui permet de combiner deux tables ou plus basées sur une ou plusieurs clés communes (attributs partagés). Cette méthode est utilisée pour enrichir un ensemble de données avec des informations complémentaires provenant d'autres tables.

Il existe différents types de jointures :

- Interne : Ne garde que les enregistrements ayant des correspondances dans les deux tables.
- Externe : Peut être totale, gardant tous les enregistrements des deux tables, ou partielle (gauche ou droite), incluant tous les enregistrements d'une table et seulement les correspondances de l'autre.
- Croisée : Combine chaque ligne d'une table avec toutes les lignes d'une autre.

Choisir entre concaténation et jointure dépend des données à disposition et de l'objectif de l'analyse. La concaténation est préférée pour des structures de données similaires, tandis que les jointures sont idéales pour enrichir et compléter des données à partir de différentes sources.

En résumé, la fusion de tables est un pilier de l'analyse de données, permettant de construire des ensembles de données complets et riches pour une prise de décision éclairée. La maîtrise des techniques de concaténation et de jointure est donc essentielle pour tout analyste de données.

Application en tenant compte du domaine de valeurs

1. Définition du Domaine de Valeurs :

Le "domaine de valeurs" fait référence à l'ensemble des valeurs possibles qu'une colonne spécifique peut prendre. Dans le contexte de la fusion de tables, cette notion est primordiale car elle détermine comment les enregistrements des deux tables peuvent être reliés. Par exemple, si nous fusionnons deux tables sur une colonne "ID client", le domaine de valeurs de cette colonne dans les deux tables indique quels clients sont présents et donc comment les enregistrements peuvent être combinés.

2. Construire une Nouvelle Table par Fusion :

Pour construire une nouvelle table à partir de deux tables existantes, on procède généralement par une des deux méthodes suivantes, en prenant en compte le domaine de valeurs :

Concaténation : Si le domaine de valeurs des colonnes correspondantes n'est pas un facteur (par exemple, lorsqu'on ajoute simplement des enregistrements de la même structure), on peut concaténer les tables. Cette méthode est simple mais ne nécessite pas une correspondance directe des valeurs.

Jointure : Lorsque le domaine de valeurs est crucial (par exemple, lorsqu'on souhaite combiner des informations relatives à un même élément à partir de deux tables différentes), on utilise une jointure. La jointure peut être de différents types (interne, externe, gauche, droite) selon les valeurs communes (domaine de valeurs) et le résultat souhaité.

3. Exemple Pratique :

Imaginons que nous ayons deux tables, Clients et Commandes. La table Clients contient les colonnes ID_client, Nom, Email et la table Commandes contient ID_commande, ID_client, Date.

Objectif : Créer une nouvelle table qui résume les commandes par client.

Approche : Utiliser une jointure sur la colonne ID_client, car le domaine de valeurs de cette colonne dans les deux tables permet de relier chaque commande à son client correspondant.

```
import pandas as pd

# Exemple de chargement des données

clients = pd.DataFrame({
    'ID_client': [1, 2, 3],
    'Nom': ['Alice', 'Bob', 'Charlie'],
    'Email': ['alice@example.com', 'bob@example.com', 'charlie@example.com']
})

commandes = pd.DataFrame({
    'ID_commande': [101, 102, 103],
    'ID_client': [2, 1, 3],
    'Date': ['2023-03-15', '2023-03-16', '2023-03-17']
})

# Fusion des tables

donnees_fusionnees = pd.merge(commandes, clients, on='ID_client')

# Affichage de la nouvelle table fusionnée

print(donnees_fusionnees)
```

Cette approche met en évidence la relation entre les tables basée sur le domaine de valeurs commun (ID_client), permettant de construire une nouvelle table enrichie qui combine les informations clients avec leurs commandes respectives.

En se concentrant sur la notion de domaine de valeurs, la fusion de tables devient un outil puissant pour l'analyse de données, permettant de réaliser des associations significatives entre différentes sources d'informations et d'obtenir une compréhension plus approfondie des données.